

**Aplikasi Web Pemantau Postur Beban Bebas Dengan
YOLOv11 dan MediaPipe di Derich Fitness Gym**



Oleh:

Timothy Jonathan David Teguh

C14230133

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS KRISTEN PETRA
SURABAYA
2026**

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Derich Fitness Gym merupakan tempat kebugaran komersial yang cukup padat. Fokus gym ini khususnya pada area alat beban bebas untuk gerakan *squat*, *deadlift* dan *bench press*. Latihan tersebut menuntut ketepatan postur tubuh agar gerakan dapat dilakukan dengan aman dan efektif. Jika postur tubuh kurang tepat saat menahan beban, otot dan sendi akan menerima tekanan yang kurang tepat. Berdasarkan hasil wawancara dengan pemilik Derich Fitness gym, sebagian besar member memilih berlatih tanpa bantuan *Personal Trainer* (PT). Akibatnya, mereka berlatih mandiri tanpa ada alat pengawas objektif untuk menunjukkan kebenaran gerakan. Kesalahan posisi ini sering kali tidak disadari oleh member, sehingga gerakan mereka mampu meningkatkan risiko cedera.

Berdasarkan kondisi yang telah disampaikan pemilik gym, kesalahan teknik ini juga membuat gerakan angkatan menjadi kurang terkontrol. Akibatnya, beban bisa terlepas dari genggaman atau terbanting keras ke lantai. Hal tersebut berpotensi merusak fasilitas gym seperti *barbell* dan piringan beban. Lantai latihan dan bantalan kursi *bench* juga rentan mengalami kerusakan fisik. Pihak manajemen sebenarnya sudah memasang aturan denda bagi perusak alat. Namun, aturan tersebut hanya bersifat reaktif setelah kerusakan fisik itu terjadi. Oleh karena itu, pemilik gym membutuhkan sistem pengawas yang bekerja secara *real-time*. Sistem ini nantinya memberikan umpan balik instan agar member bisa membetulkan gerakan saat itu juga.

Salah satu penelitian sejenis adalah studi dari Ko et al. (2024) yang menunjukkan kombinasi YOLOv5, MediaPipe dan Random Forest dapat digunakan untuk mengklasifikasikan postur latihan. Namun penelitian tersebut masih menggunakan pendekatan per-frame. Akibatnya, hasil prediksi rentan berubah karena gangguan visual. Selain itu, mekanisme perhitungan repetisi otomatis masih belum

dijelaskan secara khusus. Untuk mengatasi keterbatasan tersebut, proyek ini menggunakan YOLOv11 untuk mendeteksi keberadaan manusia, MediaPipe mengekstraksi titik persendian dan Random Forest untuk mengklasifikasikan postur berdasarkan fitur *joint angle* dan *joint coordinate*. Berbeda dengan penelitian sebelumnya, data pose disusun secara temporal menggunakan teknik sliding window. Tujuannya agar satu sampel dapat merepresentasikan urutan gerakan secara utuh serta mengurangi prediksi yang berubah antar-frame (Raza et al., 2025). YOLOv11 dipilih sebagai model deteksi objek yang lebih baru karena memiliki performa deteksi baik. Sementara MediaPipe tetap digunakan karena menghasilkan akurasi klasifikasi yang lebih tinggi (Kongchansawang et al., 2025).

Penelitian Hsu et al. (2024) menunjukkan bahwa data pose bisa mengidentifikasi pola gerakan berulang untuk menghitung repetisi otomatis. Data gerakan dalam proyek ini akan divalidasi bersama Personal Trainer di Derich Fitness Gym. Sistem diharapkan dapat memberikan klasifikasi postur yang lebih stabil dan menghitung jumlah repetisi secara otomatis. Aplikasi dapat diakses melalui browser serta memberikan umpan balik visual dan suara secara real-time. Pengguna juga dapat melihat ringkasan hasil evaluasi setelah latihan selesai.

1.2 Rumusan Masalah

Berdasarkan penjelasan latar belakang di atas, rumusan masalah dalam proyek ini adalah:

1. Apakah pengguna gym bisa menerima desain antarmuka visual aplikasi dengan baik melalui kuesioner skala Likert?
2. Apakah teknik sliding window mampu mendapatkan nilai F1-score yang lebih tinggi daripada model klasifikasi per-frame?
3. Apakah perubahan *joint angle* secara temporal mampu menghitung jumlah repetisi secara akurat jika dibandingkan dengan hitungan manual menggunakan metrik MAE?

1.3 Tujuan Proyek

Tujuan penelitian proyek ini adalah membangun aplikasi web untuk mengevaluasi postur latihan angkat beban secara otomatis di Derich Fitness Gym. Sistem ini menggunakan YOLOv11 untuk deteksi objek manusia, MediaPipe untuk mengekstrak koordinat titik persendian, dan Random Forest untuk mengklasifikasi postur gerakan berdasarkan fitur *joint angle* dan *joint coordinate* yang dihasilkan. Teknik sliding window digunakan agar pola gerakan dapat direpresentasikan menjadi data berbasis segmen secara stabil sebelum proses klasifikasi dilakukan. Sistem ini juga mampu mendeteksi perubahan *joint angle* untuk mengenali fase gerakan angkatan (naik dan turun) yang dijadikan dasar dalam menghitung jumlah repetisi secara otomatis. Hasil analisis deteksi akan ditampilkan dalam bentuk antarmuka visual yang dirancang agar mudah dipahami, sehingga dapat membantu pengguna memperoleh evaluasi gerakan secara objektif dan menyediakan hasil evaluasi kualitas gerakan yang dilakukan.

1.4 Ruang Lingkup

Ruang lingkup proyek ini dibatasi pada:

1. Sistem dibatasi pada tiga jenis latihan beban bebas, yaitu: *Bench Press*, *Deadlift*, *Squat*.
2. Input sistem berupa video dari satu kamera yang ditempatkan pada area evaluasi latihan yang sudah ditentukan untuk merekam pergerakan pengguna saat melakukan salah satu dari tiga jenis latihan (*squat*, *bench press*, atau *deadlift*) pada satu waktu pelaksanaannya.
3. Proses sistem meliputi:
 - a. Proses deteksi objek manusia menggunakan YOLOv11.
 - b. Proses ekstraksi koordinat titik persendian menggunakan MediaPipe.
 - c. Pengolahan data pose menjadi *joint angle* dan *joint coordinate* untuk merepresentasikan hubungan antar bagian tubuh.

- d. Normalisasi data sebelum proses klasifikasi untuk mengurangi bias model saat belajar terhadap sendi yang memiliki rentang nilai derajat yang lebih tinggi.
 - e. Pengelompokan data berbasis waktu menggunakan pendekatan sliding window agar data gerakan dapat dianalisis secara temporal
 - f. Pembentukan *relative coordinate* berdasarkan titik tengah pinggul dan panjang torso untuk mengurangi pengaruh perbedaan posisi dan skala tubuh.
 - g. Penambahan variasi data *training* menggunakan *horizontal flipping augmentation*.
 - h. Klasifikasi postur menggunakan algoritma Random Forest.
4. Dataset secara keseluruhan memiliki 18 kelas, dengan enam kelas pada masing-masing jenis latihan, yaitu:
- a. Squat: correct posture, knee inward, back bend
 - b. Deadlift: correct posture, back round, arms spread
 - c. Bench press: correct posture, flat back, arms spread
 - d. Masing-masing kategori postur akan dibagi kembali secara spesifik ke dalam fase kontraksi otot, yaitu fase Konsentrik (Concentric/gerakan naik) dan fase Eksentrik (Eccentric/gerakan turun).
5. Dataset video dikumpulkan secara mandiri dengan sudut pengambilan sekitar 45° pada diagonal kiri dan kanan agar objek beban tidak menutupi persendian saat dianalisis. Selain itu, pengambilan data juga dilakukan dari sisi depan yang digunakan sebagai data training dan perbandingan pada skenario pengujian tambahan.
6. Penggunaan dataset dalam sistem ini dibatasi pada kriteria berikut:
- a. Ciri-ciri Video: Data direkam dari minimal 3 orang partisipan yang memiliki proporsi tubuh yang berbeda dan latar belakang (*background*) yang menyesuaikan dengan kondisi asli di gym.
 - b. Jumlah Data: Total dataset bersih yang nantinya diproses oleh model berjumlah 27.081 sampel data temporal.

- c. Pembagian Data: Dataset tersebut dibagi secara proporsional dengan target porsi 70% digunakan sebagai data training dan 30% sisanya sebagai data testing.
7. Dataset yang digunakan telah divalidasi melalui konsultasi dengan Personal Trainer (PT) di Derich Fitness Gym dengan tetap mengacu pada penelitian Ko et al. (2024).
8. Perhitungan repetisi dilakukan berdasarkan perubahan fase naik dan turun gerakan yang terdeteksi dari pola perubahan joint angle pada titik persendian.
9. Implementasi sistem tidak membangun model pose estimation dari awal, tetapi menggunakan model *pre-trained* YOLOv11 dan MediaPipe yang sudah tersedia.
10. Pengujian antarmuka visual dilakukan menggunakan kuesioner skala Likert yang melibatkan pengguna gym dan pemilik gym sebagai responden.
11. Dilakukan pengujian performa klasifikasi antara pendekatan per-frame dan sliding window menggunakan metrik evaluasi, yaitu Confusion Matrix, Accuracy, Precision, Recall, dan F1-Score.
12. Akurasi perhitungan repetisi dievaluasi menggunakan Mean Absolute Error (MAE) berdasarkan perbandingan dengan ground truth.
13. Dilakukan pengujian tambahan dengan membandingkan performa YOLOv5 dan YOLOv11 berdasarkan waktu inferensi dan ketepatan deteksi objek manusia.
14. Dilakukan pengujian tambahan dengan membandingkan performa model klasifikasi antara model yang menggunakan data dua sudut diagonal dengan model yang menggunakan tambahan data sudut sisi depan untuk mengevaluasi dampak *occlusion*.
15. Output sistem berupa:
 - a. Tampilan video dengan bounding box dan skeleton pose
 - b. Informasi klasifikasi postur sesuai dengan kelas yang terdeteksi
 - c. Teks dan suara peringatan apabila terjadi kesalahan postur
 - d. Informasi jumlah repetisi latihan
 - e. Ringkasan hasil analisis setelah latihan selesai yang menampilkan jumlah repetisi dan gambar saat kesalahan terdeteksi.

16. Sistem diimplementasikan dalam bentuk aplikasi web menggunakan arsitektur *client-server* dengan pembagian proses antara sisi *client* dan *server*.

17. Batasan sistem pada proyek ini meliputi:

- Aplikasi hanya difokuskan pada proses evaluasi postur latihan beban bebas secara real-time.
- Sistem tidak mendukung multi-user tracking dalam satu frame.
- Sistem tidak melakukan identifikasi identitas pengguna secara otomatis.
- Sistem tidak mencakup fitur manajemen gym seperti pencatatan member, jadwal pelatih, dan kasir.
- Sistem tidak menyediakan fitur program latihan maupun konsultasi Personal Trainer secara langsung.

1.5 Manfaat Penelitian

Manfaat aplikasi web ini diharapkan bisa langsung dirasakan di lapangan, baik oleh kalangan tertentu maupun masyarakat luas. Aplikasi ini bisa dimanfaatkan oleh pihak pengelola gym sebagai alat evaluasi gerakan yang lebih objektif. Kualitas gerakan dapat ditingkatkan lewat hasil evaluasi yang menampilkan klasifikasi postur, visual, dan jumlah repetisi. Dengan itu sistem ini membantu mengurangi risiko kerusakan fasilitas gym akibat penggunaan alat yang tidak terkontrol karena kesalahan teknik saat latihan. Bagi pengunjung yang terbiasa latihan mandiri, aplikasi ini hadir sebagai panduan keamanan. Saat terjadi kesalahan postur, sistem akan otomatis memberi peringatan secara *real-time* sekaligus menghitung repetisi latihan mereka. Sementara dari sisi akademis, hasil tugas akhir ini bisa menjadi acuan untuk penelitian berikutnya. Khususnya pada penelitian yang memanfaatkan teknik *sliding window* dalam pengolahan data berbasis waktu pada deteksi gerak. Selain itu, hasil ini dapat menjadi acuan untuk pengembangan perhitungan repetisi berbasis pola di bidang olahraga.

1.6 Sistematika Penulisan

Penulisan skripsi ini dibagi menjadi beberapa bab, yaitu:

- **BAB I: PENDAHULUAN**

Bab ini berisikan latar belakang serta rumusan masalah dan ruang lingkup proyek. Bagian tujuan proyek serta manfaat aplikasi dan sistematika penulisan juga dibahas di sini.

- **BAB II: TAHAPAN PROYEK DAN STUDI LITERATUR**

Bab ini membahas tahapan pengerjaan proyek secara detail. Selain itu terdapat studi literatur mengenai model AI serta library pendukung.

- **BAB III: DESAIN APLIKASI**

Bab ini membahas analisis kebutuhan serta spesifikasi dataset video. Desain file, arsitektur *client-server* dengan pembagian proses antara *client* dan *server*, serta modul program juga dijelaskan di sini.

- **BAB IV: PENGUJIAN APLIKASI**

Bab ini mendokumentasikan pengujian performa model klasifikasi secara objektif. Hasil evaluasi kuesioner pengguna serta analisis skenario pengujian juga dibahas di sini.

- **BAB V: KESIMPULAN DAN SARAN**


Bab ini berisi kesimpulan akhir dari hasil pengujian sistem. Beberapa saran praktis untuk pengembangan aplikasi ke depan juga ditulis di sini.

BAB II

TAHAPAN PROYEK DAN STUDI LITERATUR

2.1 Tahapan Pengerjaan Proyek Secara Detail

Proyek ini dikembangkan melalui serangkaian tahapan yang mencakup proses pengolahan data, pelatihan model, implementasi sistem, serta pengujian. Secara umum, tahapan pengerjaan dibagi menjadi dua bagian utama, yaitu tahap *offline* untuk memvalidasi, mengolah data dan melatih model klasifikasi. Kemudian, tahap berikutnya adalah implementasi model yang telah dilatih dan diterapkan pada aplikasi web. Alur tahapan pengerjaan proyek ditunjukkan pada Gambar 2.1.



Gambar 2.1 Diagram Tahapan Pengerjaan Proyek

Berdasarkan alur kerja pada Gambar 2.1, berikut tahapan pengerjaan proyek dijelaskan sebagai berikut:

2.1.1 Identifikasi Masalah

Tahap awal proyek dilakukan dengan mengidentifikasi permasalahan dan kebutuhan yang dimiliki pemilik *gym*. Informasi diperoleh melalui wawancara mengenai kondisi latihan serta kebutuhan member. Hasil dari tahap ini digunakan sebagai dasar dalam menentukan ruang lingkup, fungsi utama, dan kebutuhan sistem yang akan dikembangkan.

2.1.2 Pengumpulan Dataset Video Latihan

Tahap pengumpulan data dilakukan secara langsung di lingkungan *gym* menggunakan video latihan *squat*, *bench press*, dan *deadlift*. Video direkam dari tiga partisipan dengan variasi tinggi badan dan proporsi tubuh yang berbeda. Pada proses perekaman dilakukan dari tiga sisi, yaitu sisi diagonal kiri dan kanan dengan sudut sekitar 45° , serta dari sisi depan sebagai data untuk skenario pengujian tambahan. Posisi kamera disesuaikan dengan kondisi masing-masing partisipan agar bagian tubuh yang diperlukan dalam proses ekstraksi *pose* dapat terlihat dengan jelas. Setelah itu, data yang telah dikumpulkan akan digunakan pada tahap pelabelan dan validasi.

2.1.3 Pelabelan dan Validasi Dataset

Video latihan dikonsultasikan dengan *personal trainer* (PT) untuk memastikan kesesuaian gerakan. Setelah itu, data diperiksa kembali untuk memastikan semua posisi tubuh terlihat dengan jelas dan tidak mengalami gangguan visual. Kemudian, data diberikan label secara manual sesuai dengan kelas postur yang telah ditentukan. Proses ini dilakukan berdasarkan jenis latihan, kondisi postur, serta fase gerakan konsentrik dan eksentrik sehingga setiap data yang diproses memiliki kelas yang sesuai.

2.1.4 Pengolahan Data untuk Pelatihan Model

Pengolahan data dilakukan untuk mengekstrak fitur dari video yang telah melalui validasi dan pelabelan sehingga dapat digunakan dalam model klasifikasi. Proses dimulai dengan menggunakan YOLOv11 untuk mendeteksi objek manusia di setiap frame. Area manusia yang terdeteksi kemudian diproses menggunakan MediaPipe untuk mendapatkan titik-titik persendian tubuh. Hasil ekstraksi tersebut selanjutnya diproses menjadi sudut sendi (*joint angle*) yang menunjukkan hubungan antar bagian tubuh.

Data fitur kemudian melalui penyaringan kualitas hasil deteksi. Pada tahap pengolahan, data *joint angle* dinormalisasi lalu disusun secara temporal menggunakan pendekatan *sliding window*. Setelah *sliding window* terbentuk, koordinat persendian dalam setiap *window* dirangkum dan dihitung menjadi *relative coordinate* menggunakan titik tengah pinggul sebagai pusat koordinat dan panjang torso sebagai faktor skala. Pada data *training* juga dilakukan *horizontal flipping augmentation* untuk menambah variasi data sebelum proses pelatihan model. Melalui proses tersebut, data tidak hanya menampilkan kondisi dalam satu *frame* tetapi juga urutan gerakan dalam beberapa *frame*.

2.1.5 Pembagian Data dan Pelatihan Model Klasifikasi

Dataset pada masing-masing jenis latihan dibagi menjadi data *training* dan *testing* dengan target perbandingan 70% dan 30%. Parameter normalisasi diperoleh dari data *training* dan digunakan kembali untuk melakukan transformasi pada data *training* dan *testing*. Setelah proses pembentukan fitur selesai, *horizontal flipping augmentation* hanya diterapkan pada data *training* untuk menambah variasi sampel. Data *training* tersebut kemudian digunakan untuk melatih model Random Forest, sedangkan data *testing* tetap menggunakan data asli tanpa augmentasi dan digunakan untuk mengevaluasi performa model.

2.1.6 Implementasi Sistem secara Real-Time

Setelah proses pelatihan selesai, model tersebut diintegrasikan ke dalam aplikasi web. Sistem menerima input video dari kamera perangkat, kemudian YOLOv11 digunakan untuk mendeteksi objek manusia, dan MediaPipe digunakan untuk mengekstraksi titik-titik tubuh. Selanjutnya, data *pose* diolah menjadi fitur *joint angle* dan *joint coordinate*. Data tersebut disusun secara temporal menggunakan *sliding window*, kemudian fitur koordinat dihitung menjadi *relative coordinate* menggunakan proses yang sama dengan tahap pelatihan sebelum digunakan oleh model Random Forest untuk menghasilkan klasifikasi postur. Selain itu, perubahan *joint angle* digunakan untuk mendeteksi fase gerakan sebagai dasar perhitungan repetisi. Hasil dari proses ini disajikan kepada pengguna dalam bentuk klasifikasi postur, jumlah repetisi, dan peringatan apabila postur salah terdeteksi.

2.1.7 Pengujian Sistem

Pengujian dilakukan setelah sistem selesai diimplementasikan untuk mengetahui performa klasifikasi postur, perhitungan repetisi, dan penerimaan pengguna. Model diuji menggunakan data *testing* dengan metrik *accuracy*, *precision*, *recall*, F1-score, dan *confusion matrix*. Performa *per-frame* juga dibandingkan dengan *sliding window*, sedangkan perhitungan repetisi dievaluasi menggunakan *Mean Absolute Error* (MAE) terhadap hasil perhitungan manual. Pengujian tambahan dilakukan dengan membandingkan YOLOv5 dan YOLOv11 serta penggunaan dua sudut diagonal dengan tambahan sudut depan. Pengujian antarmuka menggunakan kuesioner Likert 1–5 kepada minimal 15 responden dengan kriteria penerimaan rata-rata minimal 4,0 atau 80% responden memberikan penilaian positif.

2.1.8 Analisis Hasil

Hasil dari seluruh proses pengujian akan dianalisis untuk melihat performa sistem yang dikembangkan. Analisis ini dilakukan berdasarkan hasil pengujian utama, pengujian tambahan dan hasil kuesioner pengguna. Dengan hasil itu proyek mampu

mengetahui kelebihan dan keterbatasan sistem, sekaligus menjadi dasar dalam menyusun kesimpulan akhir dari proyek.

2.2 Studi literatur

2.2.1 Model yang Digunakan

2.2.1.1 YOLOv11

YOLOv11 merupakan model dari Ultralytics yang mendukung berbagai tugas *computer vision*, termasuk *object detection* (Jocher & Qiu, 2024). Dalam proyek ini, YOLOv11 berperan sebagai tahap awal untuk memastikan bahwa proses analisis hanya difokuskan pada area yang mengandung objek manusia dan hasil deteksi berupa *bounding box* yang akan menjadi data input pada tahap ekstraksi *pose*. Berdasarkan penelitian Kongchansawang et al. (2025), peneliti menggunakan YOLOv11 sebagai *baseline* untuk mendeteksi *pose* manusia. Akan tetapi, hasil penelitian menunjukkan bahwa pendekatan berbasis MediaPipe mampu menghasilkan *landmark* tubuh yang lebih lengkap dan memberikan akurasi klasifikasi yang lebih tinggi dibandingkan pendekatan YOLOv11 pada beberapa *pose*. Oleh karena itu, pada proyek ini YOLOv11 digunakan untuk mendeteksi objek manusia agar proses pengolahan data menjadi lebih terarah pada saat analisis postur.

2.2.1.2 MediaPipe

MediaPipe digunakan untuk mengekstrak titik-titik persendian manusia dari hasil deteksi objek. Output yang dihasilkan yaitu koordinat *landmark* tubuh yang merepresentasikan struktur *pose* manusia. Model ini mampu melakukan *pose estimation* secara *real-time* menggunakan kamera tunggal, sehingga dapat diterapkan pada sistem evaluasi postur latihan di lingkungan gym. Dalam alur sistem, MediaPipe berperan untuk menghasilkan data *pose* yang nantinya diolah menjadi fitur *joint angle* dan *joint coordinate* sebagai dasar proses klasifikasi. Berdasarkan Ko et al. (2024), MediaPipe digunakan untuk mengekstrak *joint landmark* yang kemudian digunakan untuk memperoleh informasi sudut antar sendi. Selain itu, Qi et al. (2025) menunjukkan

bahwa MediaPipe dapat digunakan secara efektif dalam sistem berbasis kamera tunggal untuk analisis gerakan menggunakan fitur *joint angle*.

2.2.1.3 Random Forest

Random Forest digunakan sebagai model klasifikasi untuk menentukan kategori postur berdasarkan hasil dari data pose. Cara kerja algoritma ini adalah dengan membangun sejumlah decision tree dan menggabungkan hasil prediksi dari masing-masing tree untuk menghasilkan satu keputusan akhir. Berdasarkan penelitian Farhani et al. (2022) bahwa Random Forest dapat mengklasifikasikan postur dengan tingkat akurasi yang tinggi. Dalam proyek ini Random Forest digunakan untuk mengklasifikasikan postur latihan berdasarkan fitur *joint angle*, *joint coordinate*, dan *relative coordinate* yang telah diproses secara temporal menggunakan pendekatan *sliding window*.

2.2.2 Teknik Pengolahan Data dan Library Pendukung

2.2.2.1 Joint Angle (Representasi Fitur)

Data pose yang diperoleh dari proses pose estimation berupa koordinat landmark persendian tubuh. Koordinat tersebut selanjutnya dapat digunakan untuk menghitung sudut antar sendi (*joint angle*). *Joint angle* dihitung dari hubungan tiga titik persendian yang saling terhubung, sedangkan *joint coordinate* merupakan posisi titik persendian dalam ruang yang direpresentasikan dalam bentuk koordinat. Data ini digunakan untuk menggambarkan hubungan geometris antar bagian tubuh dalam suatu gerakan. Berdasarkan penelitian Qi et al. (2025), penggunaan *joint angle* dapat memberikan representasi yang lebih seragam dan stabil dalam evaluasi postur karena nilai sudut secara langsung merepresentasikan hubungan antar bagian tubuh dalam suatu gerakan. Selain itu, Hamilton et al. (2024) menunjukkan bahwa MediaPipe dapat digunakan untuk memperoleh pengukuran *joint angle* yang memiliki kesesuaian yang baik dengan sistem *3D motion capture* pada sebagian besar gerakan yang diuji.

Joint coordinate digunakan untuk melengkapi informasi posisi tubuh secara spasial yang tidak sepenuhnya ditangkap oleh joint angle. Berdasarkan Ko et al. (2024) proses klasifikasi postur menggunakan kombinasi joint coordinate dan joint angle mampu meningkatkan representasi data gerakan dan menghasilkan performa klasifikasi yang lebih baik. Oleh karena itu, dalam proyek ini joint angle dirancang sebagai fitur utama dan joint coordinate sebagai fitur pendukung dalam proses klasifikasi postur.


Secara matematis, joint angle dihitung berdasarkan hubungan vektor dari tiga titik persendian. Garis imajiner yang menghubungkan dua titik persendian secara matematis dibaca oleh sistem komputer sebagai vektor garis lurus, bukan sebagai kurva lengkungan otot. Terdapat tiga titik A, B, dan C, maka sudut pada titik B dapat dihitung menggunakan persamaan berikut:

$$\theta_{deg} = \cos^{-1} \left(\frac{BA \cdot BC}{|BA||BC|} \right) \times \left(\frac{180}{\pi} \right) \dots\dots\dots (1)$$

Di mana BA dan BC merupakan vektor yang dihasilkan dari titik persendian, serta θ_{deg} merupakan besar sudut dalam satuan derajat. Konsep penarikan vektor garis lurus ini diilustrasikan pada Gambar 2.2.



Gambar 2.2 Ilustrasi penarikan vektor garis lurus pada persendian (Sumber: Ko et al., 2024)



Gambar 2.3 Peta 33 titik landmark MediaPipe (Sumber: Ko et al., 2024)

Mengacu pada penelitian Ko et al. (2024), koordinat dari 33 titik tersebut dapat digunakan untuk menghitung 11 sudut sendi utama (*Joint Angles*) sebagai fitur klasifikasi, yaitu:

- Sudut Leher (*Neck Angle*)
- Sudut Bahu Kiri & Kanan (*Left/Right Shoulder Angle*)
- Sudut Siku Kiri & Kanan (*Left/Right Elbow Angle*)
- Sudut Pinggul Kiri & Kanan (*Left/Right Hip Angle*)
- Sudut Lutut Kiri & Kanan (*Left/Right Knee Angle*)
- Sudut Pergelangan Kaki Kiri & Kanan (*Left/Right Ankle Angle*)

Dengan perhitungan seperti ini, sistem dapat mengevaluasi hubungan antar sendi dalam suatu gerakan sehingga dapat digunakan sebagai dasar dalam menentukan kebenaran postur.

2.2.2.2 Sliding Window (Data Temporal)

Data pose didapatkan dari setiap frame yang memiliki karakteristik berurutan dan dalam bentuk data berbasis waktu. Dengan itu cara untuk memanfaatkan informasi tersebut, digunakan pendekatan sliding window yang mengelompokkan data menjadi bentuk segmen berdasarkan waktu dalam urutan frame. Berdasarkan penelitian Raza et al. (2025), pendekatan *sliding window* digunakan untuk menggabungkan fitur *skeleton* secara berurutan sehingga setiap segmen terdiri dari sejumlah *frame* yang digunakan sebagai satu unit sebelum proses klasifikasi. Arrowsmith et al. (2023) juga menggunakan pendekatan *sliding window* pada data *pose* berbasis waktu untuk melakukan klasifikasi latihan menggunakan video dari satu kamera. Selain itu, jumlah *frame* per detik (*frame per second*) dan durasi waktu tertentu menentukan ukuran *window*, sehingga setiap *window* merepresentasikan satu potongan aktivitas dalam rentang waktu tertentu.

Secara matematis, panjang window (sliding window length) dapat dirumuskan sebagai berikut:

$$swl = fps \times t \dots\dots\dots (2)$$

Di mana fps merupakan jumlah frame per detik, dan t merupakan durasi waktu dalam detik. Pada pendekatan Raza et al. (2025), setiap *window* digeser sebanyak satu *frame* hingga mencapai bagian akhir video. Selain dari itu, jumlah total *window* yang dihasilkan dari suatu video dapat dihitung menggunakan persamaan berikut:

$$swm = Frames_{video} - swl + 1 \dots\dots\dots (3)$$

Di mana $Frames_{video}$ merupakan jumlah total frame dalam video, dan swm merupakan total jumlah segmen sliding window yang dihasilkan. Dengan pendekatan ini, setiap sliding window yang berisi sekumpulan frame dapat merepresentasikan rangkaian gerakan dalam rentang waktu tertentu. Hal ini yang menjadi dasar atau inputan untuk melakukan klasifikasi berdasarkan pola gerakan secara temporal.

2.2.2.3 Repetition Counting Berbasis Skeleton

Perhitungan repetisi pada proyek ini dilakukan dengan memanfaatkan data pose berbasis waktu yang membentuk pola gerakan berulang. Proses ini dilakukan dengan melihat perubahan data antar frame dalam satu rangkaian gerakan. Berdasarkan penelitian Hsu et al. (2024), data skeleton dari pose estimation dapat digunakan untuk mengidentifikasi pola gerakan berulang secara temporal. Hal ini memungkinkan sistem melakukan perhitungan repetisi secara otomatis pada berbagai sudut pandang kamera. Kemiripan antar frame dalam suatu rangkaian gerakan dapat dianalisis menggunakan cosine similarity sebagai berikut:

$$\cos(\theta) = \frac{A \cdot B}{|A||B|} \dots\dots\dots (4)$$

Di mana A dan B merupakan representasi fitur pose pada dua frame yang berbeda. Nilai cosine similarity digunakan untuk melihat kemiripan pola gerakan dalam

suatu sequence. Setelah itu, jumlah repetisi dihitung dengan melihat siklus gerakan dari perubahan nilai joint angle secara temporal. Satu repetisi dihitung ketika gerakan mencapai titik maksimum sesudah melewati titik minimum. Modul perhitungan repetisi tidak mempengaruhi proses klasifikasi postur, akan tetapi digunakan sebagai informasi tambahan dalam menyusun hasil evaluasi postur.

2.2.2.4 Normalisasi Data

Data joint angle yang dihasilkan dari proses ekstraksi memiliki rentang nilai yang berbeda-beda, sehingga perlu adanya normalisasi data untuk memastikan setiap fitur berada pada skala yang sama. Hal ini membantu mengurangi pengaruh perbedaan skala antar fitur dalam proses training. Berdasarkan penelitian Ko et al. (2024), proses normalisasi dilakukan menggunakan metode min-max scaling untuk mengubah nilai joint angle ke dalam rentang [0,1]. Dengan pendekatan ini, distribusi data menjadi lebih konsisten sehingga model dapat mempelajari pola gerakan secara lebih optimal.

Secara matematis, proses normalisasi dapat dirumuskan sebagai berikut:

$$\theta' = \frac{\theta - \theta_{min}}{\theta_{max} - \theta_{min}} \dots\dots\dots (5)$$

Di mana θ merupakan nilai joint angle asli, θ_{min} dan θ_{max} merupakan nilai minimum dan maksimum yang diperoleh dari data *training*, sedangkan θ' merupakan hasil dari normalisasi. Dalam penelitian proyek ini, proses normalisasi dilakukan setelah ekstraksi fitur joint angle dan sebelum proses klasifikasi. Setelah proses tersebut, data yang digunakan menjadi lebih konsisten sebelum dimasukkan sebagai input ke dalam model.

2.2.2.5 Relative Coordinate Normalization

Koordinat *landmark* yang dihasilkan dari proses *pose estimation* dapat dipengaruhi oleh posisi tubuh pada *frame*, ukuran tubuh, dan jarak pengguna terhadap kamera. Lee et al. (2026) menggunakan pendekatan *hip-centered spatial normalization*

untuk mengurangi pengaruh tersebut dengan menjadikan titik tengah pinggul sebagai pusat koordinat dan jarak antara titik tengah bahu dan pinggul sebagai faktor skala.

Titik tengah pinggul digunakan sebagai pusat koordinat tubuh dan dihitung dari rata-rata koordinat pinggul kiri dan kanan sebagai berikut:

$$C_{hip} = \frac{H_L + H_R}{2} \dots\dots\dots (6)$$

Selanjutnya, titik tengah bahu dihitung dari rata-rata koordinat bahu kiri dan kanan:

$$C_{shoulder} = \frac{S_L + S_R}{2} \dots\dots\dots (7)$$

Panjang torso digunakan sebagai faktor skala dan dihitung berdasarkan jarak Euclidean antara titik tengah bahu dan titik tengah pinggul:

$$S = ||c_{shoulder} - c_{hip}|| \dots\dots\dots (8)$$

Setelah itu, koordinat setiap persendian diubah menjadi koordinat relatif dengan menjadikan titik tengah pinggul sebagai pusat dan panjang torso sebagai faktor skala:

$$P_{rel} = \frac{P - C_{hip}}{S} \dots\dots\dots (9)$$

Di mana H_L dan H_R merupakan koordinat pinggul kiri dan kanan, S_L dan S_R merupakan koordinat bahu kiri dan kanan, P merupakan koordinat persendian, S merupakan panjang torso, dan P_{rel} merupakan hasil koordinat relatif. Dengan pendekatan tersebut, pengaruh perbedaan posisi dan skala tubuh terhadap koordinat dapat dikurangi. Lee et al. (2026) menjelaskan bahwa proses normalisasi menghasilkan representasi koordinat yang *scale-invariant* dan tidak bergantung pada *global*

translation. Dalam proyek ini, prinsip tersebut diadaptasi pada koordinat yang telah dirangkum dalam setiap *sliding window* sebelum digunakan sebagai fitur klasifikasi.

2.2.2.6 Horizontal Flipping Augmentation

Horizontal flipping augmentation digunakan untuk menambah variasi data *training* dengan mencerminkan posisi koordinat secara horizontal. Zhu & Zhu (2021) menerapkan proses *horizontal flipping* dengan membalik koordinat horizontal dan menukar pasangan persendian kiri dengan persendian kanan yang bersesuaian.

Pada proyek ini, koordinat horizontal berada pada rentang 0–1 sehingga rumus *horizontal flipping* diadaptasi menjadi:

$$x' = 1 - x \dots\dots\dots (10)$$

Di mana x merupakan koordinat horizontal awal dan x' merupakan koordinat setelah *horizontal flipping*. Setelah pencerminan dilakukan, pasangan *landmark* kiri dan kanan ditukar agar struktur tubuh tetap konsisten. *Horizontal flipping augmentation* hanya diterapkan pada data *training*, sedangkan data *testing* dan data pada implementasi *real-time* tidak melalui proses augmentasi.

2.2.2.7 Evaluasi Model

Evaluasi model pada penelitian ini mengacu pada metrik yang digunakan oleh Ko et al. (2024) yaitu *accuracy*, *precision*, *recall*, dan *F1-score* untuk mengukur performa klasifikasi postur. Selain itu, *confusion matrix* digunakan untuk melihat hasil prediksi model pada masing-masing kelas postur. Dari beberapa metrik tersebut, F1-score digunakan sebagai indikator utama karena mempertimbangkan nilai *precision* dan *recall*.

Secara matematis, F1-score dirumuskan sebagai berikut:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \dots\dots\dots (11)$$

Dalam penelitian proyek ini, hasil evaluasi digunakan untuk melihat performa pada algoritma klasifikasi. Selain evaluasi klasifikasi, hasil perhitungan repetisi dievaluasi menggunakan *Mean Absolute Error* (MAE) yang mengacu pada Hsu et al. (2024). Metrik ini menghitung rata-rata selisih absolut antara jumlah repetisi yang dihasilkan sistem dan *ground truth*, kemudian dinormalisasi terhadap jumlah repetisi *ground truth* pada setiap video. Secara matematis, *MAE* dirumuskan sebagai berikut:

$$MAE = \frac{1}{n} \sum_{i=1}^n \frac{|C_i^{\wedge} - C_i|}{C_i} \dots\dots\dots (12)$$

Di mana n merupakan jumlah video pengujian, $C_i^{\wedge}$ merupakan jumlah repetisi yang dihasilkan sistem pada video ke- i , dan C_i merupakan jumlah repetisi sebenarnya berdasarkan perhitungan manual sebagai *ground truth*. Nilai *MAE* yang semakin kecil menunjukkan tingkat kesalahan relatif perhitungan repetisi yang semakin rendah.

2.2.2.8 Library dan Framework yang Digunakan

Pada penelitian proyek ini, beberapa library dan framework digunakan untuk mendukung proses pengembangan sistem, yaitu:

- MediaPipe digunakan untuk melakukan pose estimation dan menghasilkan koordinat titik persendian tubuh dari input video.
- YOLOv11 digunakan untuk mendeteksi keberadaan objek manusia dalam frame video sehingga proses analisis difokuskan pada area yang relevan.
- Scikit-learn digunakan untuk implementasi algoritma Random Forest dalam proses klasifikasi postur.

- OpenCV digunakan untuk pengolahan video dan pengambilan frame dari input kamera.

2.2.3 Penelitian Terdahulu / State-of-the-Art

2.2.3.1 Real-Time AI Posture Correction for Powerlifting Exercises Using YOLOv5 and MediaPipe (Ko et al., 2024)

Masalah yang diangkat dalam penelitian ini adalah kurangnya alat bantu yang mampu mengevaluasi postur secara otomatis dan objektif, terutama pada latihan yang menggunakan beban seperti *squat*, *bench press*, dan *deadlift*. Hal ini dikarenakan oleh keterbatasan pada evaluasi postur secara manual yang sangat bergantung pada pengamatan manusia yang kurang konsisten dan sering kali bersifat subjektif. Oleh karena itu, dibutuhkan sebuah sistem yang dapat mengevaluasi postur berdasarkan data sendi-sendi manusia yang digunakan untuk melakukan proses klasifikasi secara otomatis sehingga mengurangi risiko cedera dan memberikan hasil yang lebih objektif.

Metode yang digunakan dalam penelitian ini merupakan kombinasi YOLOv5, MediaPipe, dan algoritma machine learning. Untuk mendeteksi keberadaan manusia dalam satu frame digunakan YOLOv5, kemudian untuk mengekstrak titik-titik sendi *pose* per frame digunakan MediaPipe. Data *pose* tersebut diolah menjadi fitur berupa sudut antar sendi (*joint angle*) dan koordinat sendi yang digunakan sebagai pengujian pada beberapa algoritma klasifikasi seperti Logistic Regression, Ridge Classifier, Random Forest, Gradient Boosting, serta beberapa model deep learning seperti FCNN, MLP-Mixer, dan Transformer. Salah satu hasil penelitian berhasil menunjukkan bahwa pada gerakan *bench press* algoritma Random Forest merupakan model yang terbaik dengan F1-score sebesar 0.970, lebih tinggi ketimbang Logistic Regression yang mendapatkan 0.958, Ridge Classifier sebesar 0.948, dan Gradient Boosting sebesar 0.948 juga. Pada model deep learning ternyata hasilnya lebih rendah di mana FCNN mendapatkan F1-score sebesar 0.921 dan MLP-Mixer sebesar 0.688. Meskipun begitu model Transformer masih mendapatkan hasilnya tinggi dengan F1-score sebesar 0.958.

Perbedaan antara penelitian ini dengan skripsi proyek ini terletak pada pendekatan pengolahan data yang digunakan. Penelitian ini masih menggunakan pendekatan berbasis *per frame*, sehingga hasil klasifikasi dapat mengalami perubahan antar *frame* karena setiap *frame* dianalisis secara terpisah. Selain dari itu, mekanisme perhitungan repetisi pada penelitian ini belum dijelaskan dan diuji secara khusus. Proyek ini akan menggunakan sliding window untuk pendekatan berbasis temporal, serta menambahkan fitur perhitungan repetisi berdasarkan data pose pada gerakan yang berulang.

2.2.3.2 Automated Classification of User Exercise Poses in Virtual Reality Using Machine Learning-Based Human Pose Estimation (Kongchansawang et al., 2025)

Masalah yang diangkat dalam penelitian ini adalah kebutuhan adanya sistem yang mampu mengklasifikasikan postur latihan secara otomatis dan objektif berdasarkan data *pose* manusia. Evaluasi gerakan masih tergantung pada pengamatan manusia secara manual, sehingga hasilnya masih bersifat subjektif dan kurang konsisten. Oleh karena itu, dibutuhkan pendekatan yang mampu mengekstraksi informasi posisi sendi tubuh dan menggunakannya sebagai dasar untuk klasifikasi postur secara otomatis.

Metode yang digunakan dalam penelitian ini membandingkan dua pendekatan *human pose estimation*, yaitu MediaPipe Holistic dan YOLOv11. MediaPipe digunakan untuk mengekstraksi 75 landmark tubuh yang terdiri dari koordinat x, y, z, serta nilai visibility. Setelah itu, data yang didapatkan tersebut digunakan sebagai fitur untuk melatih model klasifikasi berbasis Stacking Classifier. Selain dari itu, penelitian ini juga menguji YOLOv11 sebagai baseline untuk mendeteksi *pose* manusia. Hasil penelitian tersebut menunjukkan bahwa MediaPipe menghasilkan landmark tubuh lebih lengkap dan akurasi klasifikasi sebesar 94%, sedangkan dengan pendekatan YOLOv11 hasilnya lebih rendah pada beberapa *pose*.

Perbedaan antara penelitian ini dengan skripsi proyek ini terletak pada tujuan dan rancangan sistem yang dikembangkan. Penelitian ini lebih fokus terhadap klasifikasi *pose* latihan dalam lingkungan *virtual reality* dengan menggunakan Stacking Classifier, sedangkan skripsi proyek ini mengembangkan aplikasi web untuk pemantauan postur latihan beban bebas di gym. Pada proyek ini, YOLOv11 hanya digunakan sebagai tahap deteksi objek manusia, MediaPipe digunakan untuk mengekstraksi koordinat titik persendian, dan Random Forest digunakan untuk mengklasifikasikan postur berdasarkan fitur *joint angle* dan *joint coordinate*. Selain dari itu, skripsi ini menggunakan pendekatan *sliding window* untuk mengolah data *pose* secara temporal dan menambahkan fitur perhitungan jumlah repetisi secara otomatis.

2.2.3.3 Human fall detection using pose estimation: From traditional machine learning to vision transformers (Raza et al., 2025)

Masalah yang diangkat dalam penelitian ini adalah keterbatasan pendekatan dalam mendeteksi aktivitas manusia, terutama pada mode berbasis sensor maupun pendekatan single frame. Penggunaan sensor masih dinilai kurang praktis karena membutuhkan perangkat tambahan. Selain dari itu, pendekatan berbasis *single frame* masih belum mampu merepresentasikan aktivitas manusia secara utuh. Hal ini dikarenakan gerakan seperti jatuh membutuhkan informasi dari beberapa *frame* secara berurutan. Oleh karena itu penelitian ini berusaha mengembangkan sistem berbasis computer vision yang dapat memahami aktivitas manusia menjadi lebih komprehensif melalui analisis *pose* dan urutan.

Metode yang digunakan pada penelitian ini adalah pendekatan berbasis *pose estimation* dengan memanfaatkan data skeleton yang diekstraksi dari video. Selain itu, penelitian ini menggunakan beberapa teknik *pose estimation* seperti AlphaPose, OpenPose, BlazePose, HRNet, dan OpenPifPaf untuk mendapatkan titik-titik persendian tubuh. Data skeleton yang dihasilkan mampu digunakan sebagai fitur untuk melatih

berbagai model klasifikasi, baik itu machine learning seperti Random Forest, KNN, dan SVM, maupun model deep learning seperti LSTM, RNN, dan Vision Transformer.

Dalam penelitian ini, peneliti juga menggunakan pendekatan berbasis *sequence* dengan teknik *sliding window* untuk menggabungkan beberapa *frame* menjadi satu rangkaian data temporal sebelum proses klasifikasi. Pendekatan ini digunakan agar sistem dapat memanfaatkan informasi gerakan dari beberapa *frame* secara berurutan. Dengan begitu, proses klasifikasi tidak hanya melihat kondisi pada satu *frame*, tetapi juga memperhatikan perubahan gerakan dalam suatu rangkaian.

Perbedaan antara penelitian ini dengan skripsi proyek ini terletak pada fokus dan penerapan metode yang digunakan. Penelitian ini berfokus pada deteksi aktivitas manusia saat jatuh, dengan memanfaatkan pendekatan berbasis pose dan *sequence* pada berbagai model klasifikasi. Skripsi ini akan difokuskan pada klasifikasi postur latihan angkat beban dengan menggunakan kombinasi YOLOv11, MediaPipe, dan Random Forest. Selain itu, skripsi ini juga akan menggunakan *sliding window* untuk merepresentasikan pola gerakan latihan serta diintegrasikan dengan perhitungan repetisi secara otomatis.

2.2.3.4 Viewpoint-invariant exercise repetition counting (Hsu et al., 2024)

Masalah yang diangkat dalam penelitian ini adalah keterbatasan metode *vision-based* dalam melakukan perhitungan repetisi latihan, terutama dalam menangani variasi sudut pandang kamera serta gerakan simultan dalam satu video. Selain dari itu, perhitungan repetisi juga masih jarang diteliti karena membutuhkan data berlabel yang cukup kompleks, khususnya dalam bentuk anotasi temporal. Oleh karena itu penelitian ini berusaha mengembangkan sebuah pendekatan yang mampu mengenali pola gerakan berulang secara akurat menggunakan data skeleton.

Metode yang digunakan pada penelitian ini adalah pendekatan pose estimation dengan menggunakan data skeleton dari video. Setelah itu, data tersebut dapat dianalisis

secara temporal untuk melihat kesamaan antar frame menggunakan cosine similarity. Hasil tersebut akan diproses dengan menggunakan Fast Fourier Transform (FFT) untuk mengubah data ke dalam domain frekuensi, sehingga pola gerakan berulang dapat terlihat dengan lebih jelas. Proses ini dilakukan menggunakan pendekatan sliding window untuk menangkap pola gerakan dalam satu rangkaian waktu, di mana frekuensi dominan digunakan untuk menentukan jumlah repetisi secara otomatis. Hasil dari penelitian menunjukkan bahwa metode ini mampu melakukan perhitungan repetisi dengan tingkat akurasi yang tinggi. Hal ini ditunjukkan dengan nilai Mean Absolute Error (MAE) sebesar 0.06 serta Off-by-One Accuracy (OBOA) mencapai 0.94 hingga 0.95 pada dataset yang digunakan. Selain dari itu, metode ini juga tahan terhadap noise dan missing data, serta mampu bekerja pada berbagai sudut pandang kamera.

Perbedaan antara penelitian ini dengan skripsi proyek ini terletak pada fokus dan penerapan sistem. Penelitian ini berfokus pada perhitungan repetisi latihan berdasarkan pola gerakan berulang tanpa adanya klasifikasi postur secara spesifik. Skripsi ini tidak hanya melakukan perhitungan repetisi, tetapi juga mengintegrasikan klasifikasi postur latihan angkat beban dengan kombinasi YOLOv11, MediaPipe, dan Random Forest. Selain itu, skripsi ini juga menggunakan pendekatan temporal berbasis *sequence*. Namun, terdapat perbedaan pada metode perhitungan repetisi yang digunakan. Penelitian Hsu et al. (2024) menggunakan analisis frekuensi dengan FFT, sedangkan skripsi proyek ini menggunakan perubahan *joint angle* secara temporal untuk menentukan satu siklus repetisi.

2.2.3.5 Tabel perbandingan

Aspek	Ko et al. (2024)	Raza et al. (2025)	Hsu et al. (2024)	Kongchansawang et al. (2025)	Proyek Ini
Fokus	Klasifikasi postur	Deteksi aktivitas	Perhitungan repetisi	Klasifikasi pose	Klasifikasi postur +

	latihan	manusia (fall detection)			repetisi
Data	Pose (joint angle + coordinate)	Pose skeleton	Pose skeleton	Landmark tubuh	Pose (joint angle + coordinate)
Pendekatan	Per-frame	Sequence (sliding window)	Sequence + FFT	Per-frame	Sequence (sliding window)
Model	ML + DL (RF terbaik)	ML & DL (LSTM, Transformer)	Analisis frekuensi	Stacking Classifier	Random Forest
Output	Klasifikasi postur	Klasifikasi aktivitas	Jumlah repetisi	Klasifikasi pose	Postur + repetisi
Kelebihan	Akurasi tinggi	Memanfaatkan informasi temporal antar-frame	Akurat untuk repetisi	Mendukung YOLOv11	Integrasi klasifikasi + repetisi
Keterbatasan	Tidak temporal	Tidak spesifik ke postur gym	Tidak klasifikasi postur	Tidak menghitung repetisi	Fokus pada implementasi sistem

BAB III

DESAIN APLIKASI

3.1 Analisis Masalah dan Kebutuhan

Derich Fitness Gym memiliki cukup banyak pengguna yang melakukan latihan secara mandiri tanpa didampingi oleh *Personal Trainer* (PT). Kondisi ini menjadi masalah, khususnya bagi pemula yang belum tentu mengetahui apakah postur yang dilakukan sudah benar. Berdasarkan hasil wawancara dengan pemilik gym, PT juga tidak selalu dapat mengawasi setiap pengguna ketika kondisi gym sedang ramai. Oleh karena itu, dibutuhkan alat bantu yang dapat memberikan evaluasi postur ketika pengguna sedang melakukan latihan. Aplikasi yang dikembangkan membantu pengguna mengetahui kondisi postur selama melakukan latihan *squat*, *bench press*, dan *deadlift*. Ketika terdapat kesalahan postur, sistem memberikan peringatan dalam bentuk teks dan suara secara *real-time*. Sistem juga menghitung jumlah repetisi dan memberikan ringkasan setelah latihan selesai agar pengguna dapat melihat kesalahan postur yang terjadi pada setiap siklus gerakan.

3.2 Analisis Dataset

3.2.1 Sumber dan Pengumpulan Dataset Video

Dataset pada proyek ini dikumpulkan secara mandiri melalui proses perekaman latihan di Derich Fitness Gym. Pengambilan video dilakukan pada tiga jenis latihan, yaitu *squat*, *bench press*, dan *deadlift*. Proses perekaman dibantu oleh *Personal Trainer* (PT) agar gerakan yang dilakukan sesuai dengan kondisi postur yang dibutuhkan. Setelah proses perekaman selesai, video diperiksa kembali sebelum digunakan pada tahap pengolahan data. Video direkam menggunakan kamera belakang smartphone dengan resolusi 1080p dan *frame rate* 30 fps. Kamera ditempatkan menggunakan tripod agar posisi tetap stabil selama perekaman. Video yang sudah didapatkan kemudian diperiksa untuk memastikan bagian tubuh dan titik persendian yang dibutuhkan terlihat dengan jelas sehingga dapat digunakan pada proses ekstraksi *pose*.

3.2.2 Karakteristik Partisipan dan Sudut Pengambilan Video

Dataset pada proyek ini menggunakan tiga partisipan dengan tinggi dan proporsi tubuh yang berbeda. Partisipan pertama memiliki tinggi sekitar 168 cm, partisipan kedua sekitar 174 cm, dan partisipan ketiga sekitar 154 cm. Partisipan pertama dan kedua merupakan *Personal Trainer* (PT), sedangkan partisipan ketiga merupakan lifter yang sudah berpengalaman. Penggunaan tiga partisipan dilakukan agar data yang dikumpulkan memiliki variasi karakteristik tubuh. Perekaman dilakukan di Derich Fitness Gym dengan kondisi latar belakang dan pencahayaan aktual. Posisi kamera disesuaikan untuk mengurangi occlusion agar bagian tubuh terlihat jelas.

Video diambil dari tiga posisi kamera, yaitu diagonal kiri, diagonal kanan, dan depan. Untuk posisi diagonal digunakan acuan sudut sekitar 45° , tetapi posisi kamera dapat disesuaikan dengan kondisi masing-masing partisipan. Penyesuaian dilakukan agar seluruh 33 *landmark* MediaPipe dapat terdeteksi dengan jelas selama gerakan. Hal ini diperlukan karena setiap *frame* yang digunakan harus memiliki data *landmark* yang lengkap sebelum dapat digunakan dalam pembentukan *sliding window*. Data dari ketiga sudut tersebut digunakan dalam proses pelatihan model. Selain itu, data sudut depan juga digunakan pada pengujian tambahan untuk membandingkan performa model yang menggunakan dua sudut diagonal dengan model yang menggunakan tiga sudut kamera.

3.2.3 Kelas dan Struktur Label Dataset

Dataset pada proyek ini dibagi berdasarkan tiga jenis latihan, yaitu *bench press*, *squat*, dan *deadlift*. Setiap latihan memiliki tiga kondisi postur yang terdiri dari satu postur benar dan dua postur salah. Masing-masing kondisi postur kemudian dibagi kembali berdasarkan fase gerakan konsentrik (*concentric*) dan eksentrik (*eccentric*). Pembagian kelas yang digunakan pada dataset dapat dilihat pada Tabel 3.1.

Jenis Latihan	Fase Gerakan	Klasifikasi Postur	Label Kelas	Jumlah Sampel
Bench Press	Concentric (naik)	Correct Posture	benchpress_correct_concentric	1.311

		Flat Back	benchpress_flatback_concentric	1.183
		Arms Spread	benchpress_armsspread_concentric	1.257
	Eccentric (turun)	Correct Posture	benchpress_correct_eccentric	1.032
		Flat Back	benchpress_flatback_eccentric	1.447
		Arms Spread	benchpress_armsspread_eccentric	946
Squat	Concentric (naik)	Correct Posture	squat_correct_concentric	1.890
		Knee Inward	squat_kneeinward_concentric	2.020
		Back Bend	squat_backbend_concentric	1.617
	Eccentric (turun)	Correct Posture	squat_correct_eccentric	1.387
		Knee Inward	squat_kneeinward_eccentric	1.060
		Back Bend	squat_backbend_eccentric	868
Deadlift	Concentric (naik)	Correct Posture	deadlift_correct_concentric	2.327
		Back Round	deadlift_background_concentric	2.042
		Arms Spread	deadlift_armsspread_concentric	2.371
	Eccentric (turun)	Correct Posture	deadlift_correct_eccentric	1.675
		Back Round	deadlift_background_eccentric	1.251
		Arms Spread	deadlift_armsspread_eccentric	1.397

Tabel 3.1 Kelas dan Struktur Label Dataset

Setiap kombinasi antara jenis latihan, kondisi postur, dan fase gerakan digunakan sebagai satu kelas yang berbeda. Dengan pembagian tersebut, terdapat enam kelas pada setiap jenis latihan sehingga jumlah keseluruhan kelas pada dataset adalah 18 kelas. Kolom label kelas menunjukkan nama label yang digunakan pada data hasil pengolahan, sedangkan jumlah sampel menunjukkan banyaknya sampel temporal yang tersedia pada masing-masing kelas setelah proses pembentukan *sliding window*.

3.2.4 Validasi Dataset

Proses validasi dataset dilakukan selama dan setelah pengambilan video. Pada saat perekaman, *Personal Trainer* (PT) membantu memastikan gerakan yang dilakukan sesuai dengan kondisi postur yang dibutuhkan pada masing-masing kelas. Setelah video diterima, data diperiksa kembali untuk memastikan gerakan dapat terlihat dengan jelas dan seluruh 33 *landmark* MediaPipe dapat terdeteksi pada *frame* yang digunakan. *Frame* yang tidak memiliki data landmark lengkap tidak digunakan dalam pembentukan sampel temporal. Pemeriksaan ini dilakukan sebelum data masuk ke tahap pengolahan dan pembentukan *sliding window*.

3.2.5 Komposisi dan Pembagian Dataset

Setelah proses ekstraksi data, data dikelompokkan berdasarkan *run*. Data kemudian dibagi menjadi data *training* dan *testing*. Setelah pembagian selesai, data dibentuk menjadi *sliding window* dengan ukuran 15 *frame*. Dari proses tersebut diperoleh total 27.081 sampel temporal. Jumlah tersebut terdiri dari 7.176 sampel *bench press*, 8.842 sampel *squat*, dan 11.063 sampel *deadlift*.

Pembagian data dilakukan berdasarkan *run*, yaitu rangkaian *frame* berurutan yang memiliki kelas postur dan fase gerakan yang sama. Dalam satu repetisi terdapat *run* fase konsentrik dan *run* fase eksentrik. Setiap *run* kemudian ditempatkan seluruhnya pada data *training* atau *testing* agar bagian gerakan yang sama tidak terbagi pada kedua kelompok data.

Dataset pada setiap jenis latihan kemudian dibagi menjadi data *training* dan *testing* berdasarkan *run* dengan target perbandingan 70% dan 30%. Pembagian dataset untuk masing-masing latihan dapat dilihat pada Tabel 3.2.

Jenis Latihan	Total Sampel	Training	Testing
Bench Press	7.176	5.308	1.868
Squat	8.842	6.365	2.477
Deadlift	11.063	7.976	3.087
Total	27.081	19.649	7.432

Tabel 3.2 Pembagian Dataset Training dan Testing per Jenis Latihan

Data *training* dari masing-masing jenis latihan digunakan untuk melatih model Random Forest secara terpisah, sedangkan data *testing* digunakan untuk mengevaluasi performa model pada latihan yang sama. Dengan pembagian tersebut, data *bench press*, *squat*, dan *deadlift* tidak dicampurkan dalam proses pelatihan model.

3.3 Desain dan Perancangan Aplikasi

3.3.1 Desain File yang Digunakan

Aplikasi yang dikembangkan tidak menggunakan database karena sistem tidak memiliki fitur akun pengguna maupun penyimpanan riwayat latihan secara permanen. Data yang dibutuhkan oleh aplikasi disimpan dalam bentuk file model dan file pendukung yang digunakan pada proses deteksi, ekstraksi *pose*, normalisasi, dan klasifikasi postur. File yang digunakan pada aplikasi terdiri dari model YOLO11n, model MediaPipe, serta model Random Forest untuk masing-masing jenis latihan yang telah dilengkapi dengan *scaler* hasil proses *training*. Selain itu, terdapat beberapa file program yang digunakan untuk menjalankan proses pada sisi *client* dan *server*.

File / Komponen	Lokasi	Fungsi
yolo11n_640.onnx	Client	Model YOLO11n untuk mendeteksi objek manusia pada video di browser.
pose_landmarker_full.task	Client	Model MediaPipe Tasks API untuk mengekstraksi 33 landmark tubuh.
@mediapipe/tasks-vision	CDN / Client	Library dan runtime MediaPipe Tasks API yang dimuat melalui CDN saat aplikasi dibuka.
ONNX Runtime Web	CDN / Client	Runtime untuk menjalankan model YOLO11n berformat ONNX pada browser.
benchpress_rf.pkl	Server	Model Random Forest beserta <i>scaler</i> untuk klasifikasi enam kelas <i>bench press</i> .
squat_rf.pkl	Server	Model Random Forest beserta <i>scaler</i> untuk klasifikasi enam kelas <i>squat</i> .
deadlift_rf.pkl	Server	Model Random Forest beserta <i>scaler</i> untuk klasifikasi enam kelas <i>deadlift</i> .

index.html	Client	Menangani antarmuka, input kamera/upload video, MediaPipe Tasks API, dan visualisasi hasil.
yolo.js	Client	Menjalankan inferensi YOLO11n pada browser.
crop.js	Client	Mengatur area crop berdasarkan bounding box hasil deteksi manusia.
webapp/app.py	Server	Menyajikan halaman web (HTML, JS, model) dan menangani komunikasi WebSocket antara client dan server
landmark_pipeline.py	Server	Mengolah landmark, membentuk fitur temporal, menjalankan pipeline klasifikasi, repetition counting, dan evaluasi siklus.

Tabel 3.3 File yang Digunakan pada Aplikasi


Model Random Forest disimpan secara terpisah untuk setiap jenis latihan karena *bench press*, *squat*, dan *deadlift* memiliki model klasifikasi masing-masing. Setiap model digunakan untuk mengklasifikasikan enam kelas yang terdiri dari tiga kondisi postur dan dua fase gerakan. Pada setiap file model juga terdapat *scaler* yang diperoleh dari data *training* masing-masing latihan. *Scaler* tersebut digunakan kembali pada saat aplikasi dijalankan agar proses normalisasi menggunakan parameter yang sama dengan proses *training*.

3.3.2 Desain Aplikasi Secara General

Aplikasi dirancang menggunakan arsitektur *client-server* dengan proses pengolahan yang dibagi antara sisi *client* dan *server*. Sisi *client* menangani input video, deteksi manusia menggunakan YOLOv11, ekstraksi *landmark* menggunakan MediaPipe, serta visualisasi hasil. Sementara itu, sisi *server* menangani pengolahan fitur temporal, klasifikasi postur menggunakan Random Forest, perhitungan repetisi, dan evaluasi setiap siklus gerakan.

Setelah MediaPipe menghasilkan data *landmark*, data tersebut dikirim dari *client* ke *server* melalui komunikasi WebSocket. Dengan demikian, video tidak perlu dikirim dan diproses seluruhnya pada sisi *server*. Hasil pengolahan berupa klasifikasi postur, jumlah repetisi, dan hasil evaluasi siklus kemudian dikirim kembali ke *client* untuk

ditampilkan kepada pengguna dalam bentuk informasi visual dan peringatan suara. Alur umum aplikasi dapat dilihat pada Gambar 3.1.



Gambar 3.1 Desain Arsitektur Client-Server pada Aplikasi Pemantau Postur

3.3.3 Desain Modul Sistem

3.3.3.1 Modul Pengolahan Data dan Pelatihan Model


Modul pengolahan data dan pelatihan model digunakan untuk mengolah dataset video sebelum digunakan pada proses pelatihan Random Forest. Proses dimulai dengan mendeteksi objek manusia pada setiap *frame* menggunakan YOLO11n. Setelah itu, area manusia yang terdeteksi dilakukan proses *crop* dan digunakan sebagai input pada MediaPipe. MediaPipe digunakan untuk mengekstraksi 33 *landmark* tubuh yang kemudian digunakan untuk menghitung 11 *joint angle* dan mengambil *joint coordinate*. Landmark yang digunakan dalam perhitungan joint angle memiliki nilai visibility minimal 0,6.

Setelah proses ekstraksi selesai, data dikelompokkan berdasarkan *run* kemudian dibagi menjadi data *training* dan *testing* dengan target perbandingan 70% dan 30%.

Proses normalisasi Min-Max kemudian dilakukan hanya pada data *joint angle* menggunakan nilai minimum dan maksimum dari data *training* sesuai Persamaan (5). Setelah itu, data disusun secara temporal menggunakan *sliding window* selama 0,5 detik atau 15 *frame* dengan *stride* satu *frame*. Pada setiap *window*, nilai 11 *joint angle* dari 15 *frame* tetap disusun berdasarkan urutan *frame* sehingga menghasilkan 165 fitur. Sementara itu, nilai x, y, z, dan *visibility* dari 33 *landmark* dirata-ratakan pada 15 *frame* dalam setiap *window*. Proses ini dilakukan agar setiap *landmark* memiliki satu nilai yang mewakili posisi selama satu *window* sehingga menghasilkan 132 fitur rata-rata *landmark*.

Koordinat rata-rata tersebut kemudian digunakan untuk membentuk 66 fitur *relative coordinate* dengan mengadaptasi prinsip Lee et al. (2026) sesuai Persamaan (6) sampai Persamaan (9). Pada proyek ini, proses *relative coordinate* dilakukan pada nilai koordinat x dan y yang telah dirangkum dalam setiap *sliding window*, bukan pada setiap *frame*. Dengan proses tersebut, setiap sampel memiliki total 363 fitur yang terdiri dari 165 fitur *joint angle*, 132 fitur rata-rata *landmark*, dan 66 fitur *relative coordinate*. Setelah seluruh fitur selesai dibentuk, *horizontal flipping augmentation* hanya diterapkan pada data *training* sesuai Persamaan (10), sedangkan data *testing* tetap menggunakan data asli. Data *training* tersebut kemudian digunakan untuk melatih model Random Forest secara terpisah pada latihan *bench press*, *squat*, dan *deadlift*.

Alur modul pengolahan data dan pelatihan model dapat dilihat pada Gambar 3.2.



Gambar 3.2 Flowchart Modul Pengolahan Data dan Pelatihan Model

Parameter yang digunakan dalam proses pengolahan data dan pelatihan model dapat dilihat pada Tabel 3.4.

Proses	Parameter	Nilai
YOLO11n	Confidence	0,7
Crop	Padding	0,75
Crop	Aspect ratio	9:16
MediaPipe	Model	pose_landmarker_full

MediaPipe	Jumlah landmark	33
MediaPipe	Jumlah orang	1
MediaPipe	Detection confidence	0,5
MediaPipe	Tracking confidence	0,5
Pembentukan Fitur	Joint angle	11 sudut
Pembentukan Fitur	Visibility minimum	0,6
Pembagian Data	Target training : testing	70% : 30%
Pembagian Data	Random seed	42
Sliding Window	Durasi	0,5 detik
Sliding Window	Jumlah frame	15 frame
Sliding Window	Stride	1 frame
Fitur per Window	Joint angle	165
Fitur per Window	Rata-rata landmark	132
Fitur per Window	Relative coordinate	66
Fitur per Window	Total fitur	363
Augmentasi	Data training	19.649 menjadi 39.298
Augmentasi	Data testing	7.432, tidak berubah
Random Forest	Jumlah pohon	100
Random Forest	min_samples_leaf	4
Random Forest	class_weight	balanced
Random Forest	random_state	42


Tabel 3.4 Parameter Pengolahan Data dan Pelatihan Model

3.3.3.2 Modul Klasifikasi Postur

Modul klasifikasi postur digunakan untuk melakukan klasifikasi postur ketika aplikasi menerima input dari kamera maupun video yang diunggah. Proses dimulai pada sisi *client* dengan mendeteksi objek manusia menggunakan YOLO11n yang dijalankan pada browser. Setelah itu, area manusia yang terdeteksi dilakukan proses *crop* dan digunakan sebagai input MediaPipe untuk mengekstraksi 33 *landmark* tubuh pada

setiap *frame*. Data *landmark* yang terdiri dari nilai *x*, *y*, *z*, dan *visibility* kemudian dikirim ke *server* melalui WebSocket. Pada sisi *server*, data tersebut digunakan untuk menghitung *joint angle* dan disimpan sementara dalam *buffer* untuk membentuk *sliding window* sebanyak 15 *frame*.

Alur modul klasifikasi postur dapat dilihat pada Gambar 3.3.



Gambar 3.3 Flowchart Modul Klasifikasi Postur

Setelah buffer berisi 15 *frame*, sistem membentuk 363 fitur menggunakan proses yang sama seperti pada tahap pelatihan model. Setelah fitur terbentuk, sistem memeriksa apakah seluruh fitur pada *window* tersebut valid. Apabila terdapat fitur yang tidak valid, *window* tersebut tidak digunakan untuk melakukan prediksi. Jika seluruh fitur valid, model Random Forest menghasilkan satu dari enam kelas pada setiap jenis latihan berdasarkan tiga kondisi postur dan dua fase gerakan. Fase konsentrik dan

eksentrik tetap digunakan pada proses klasifikasi, kemudian hasil klasifikasi setiap *window* diteruskan ke modul evaluasi siklus yang dijelaskan pada Subbab 3.3.3.4.

Pada sisi *client*, YOLO11n menggunakan nilai *confidence* 0,7 untuk menyaring hasil deteksi yang memiliki tingkat keyakinan rendah. NMS IoU sebesar 0,45 digunakan untuk menghilangkan hasil deteksi yang saling tumpang tindih. Proses deteksi YOLO dilakukan setiap lima *frame* dan *bounding box* terakhir digunakan pada *frame* di antaranya agar MediaPipe tetap dapat melakukan ekstraksi *landmark*. Model YOLO11n dijalankan dalam format ONNX dengan ukuran input 640. MediaPipe menggunakan GPU apabila tersedia dan menggunakan CPU apabila pemrosesan melalui GPU tidak tersedia. Parameter yang digunakan pada modul klasifikasi postur dapat dilihat pada Tabel 3.5.


Proses	Parameter	Nilai
YOLO11n	Format model	ONNX
YOLO11n	Input model	640
YOLO11n	<i>Confidence</i>	0,7
YOLO11n	NMS IoU	0,45
YOLO11n	Deteksi ulang	Setiap 5 <i>frame</i>
MediaPipe	Jumlah <i>landmark</i>	33
MediaPipe	Pemrosesan	GPU dengan cadangan CPU
WebSocket	Data yang dikirim	<i>x, y, z, visibility, dan timestamp</i>
WebSocket	<i>frame rate</i> sistem	30 fps
<i>Sliding Window</i>	Jumlah <i>frame</i>	15 <i>frame</i>
Fitur Klasifikasi	<i>Joint angle</i>	165
Fitur Klasifikasi	Rata-rata <i>landmark</i>	132
Fitur Klasifikasi	<i>Relative coordinate</i>	66
Fitur Klasifikasi	Total fitur	363
Random Forest	Jumlah kelas	6 kelas per latihan

Random Forest	Ambang <i>confidence</i>	Tidak digunakan
Data tidak valid	Perlakuan	<i>Window</i> tidak diprediksi

Tabel 3.5 Parameter Modul Klasifikasi Postur

3.3.3.3 Modul Perhitungan Repetisi

Modul perhitungan repetisi berfungsi untuk menghitung jumlah repetisi berdasarkan perubahan *joint angle* secara temporal. Proses ini berjalan terpisah dari klasifikasi Random Forest. Sudut utama berbeda pada setiap latihan. Sudut lutut dipakai untuk *squat*. Sudut siku dipakai untuk *bench press*. Sudut pinggul dipakai untuk *deadlift*. Setiap sudut memiliki nilai pada sisi kiri dan kanan tubuh. Jika kedua sisi terdeteksi dengan baik, sistem mengambil nilai rata-rata sebagai satu nilai sudut utama. Jika hanya satu sisi yang terdeteksi, nilai dari sisi tersebut dipakai. Nilai sudut kemudian dihaluskan dengan rata-rata bergerak sebanyak lima *frame* untuk mengurangi perubahan kecil antar-*frame*. Setelah itu, sistem mampu melacak arah perubahan sudut serta nilai ekstrem berupa puncak dan lembah. Alur modul perhitungan repetisi dapat dilihat pada Gambar 3.4.



Gambar 3.4 Flowchart Modul Perhitungan Repetisi

Nilai *prominence* digunakan sebagai batas minimum perubahan sudut dari nilai ekstrem sebelumnya. Jika perubahan sudut telah memenuhi batas tersebut maka titik tersebut dapat diproses sebagai kandidat titik balik. Jenis kandidat titik balik ditentukan berdasarkan arah perubahan sudut, yaitu arah naik sebagai kandidat puncak dan arah turun sebagai kandidat lembah. Kandidat titik balik juga harus memenuhi jarak minimum dari titik balik sejenis sebelumnya. Sistem juga menggunakan *cosine similarity* sesuai Persamaan (4) dengan membandingkan vektor 11 *joint angle* pada kandidat titik balik dengan titik ekstrem sejenis pertama yang telah dikonfirmasi pada sesi tersebut. Apabila seluruh kondisi terpenuhi, kandidat tersebut dikonfirmasi sebagai titik balik. Satu repetisi dihitung ketika titik puncak berhasil dikonfirmasi dan titik lembah sudah terkonfirmasi lebih dahulu.

Proses *smoothing* hanya digunakan pada modul perhitungan repetisi dan tidak diterapkan pada fitur yang digunakan oleh Random Forest. Nilai *prominence* yang digunakan adalah 12° untuk *squat*, 12° untuk *bench press*, dan 14° untuk *deadlift*. Jarak minimum antar titik balik sejenis adalah 1,6 detik untuk ketiga latihan, sedangkan ambang *cosine similarity* yang digunakan adalah 0,70. Parameter yang digunakan pada modul perhitungan repetisi dapat dilihat pada Tabel 3.6.


Proses	Parameter	Nilai
Sudut Utama	Squat	Sudut lutut
Sudut Utama	Bench press	Sudut siku
Sudut Utama	Deadlift	Sudut pinggul
Smoothing	Rata-rata bergerak	5 frame
Titik Balik	Prominence squat	12°
Titik Balik	Prominence bench press	12°
Titik Balik	Prominence deadlift	14°
Titik Balik	Jarak minimum	1,6 detik
Cosine Similarity	Ambang minimum	0,70

Tabel 3.6 Parameter Modul Perhitungan Repetisi

3.3.3.4 Modul Evaluasi Siklus Gerakan

Modul evaluasi siklus gerakan digunakan untuk merangkum hasil klasifikasi dari beberapa *sliding window* menjadi satu hasil evaluasi gerakan. Setiap hasil klasifikasi *window* disimpan bersama nilai sudut utama sesuai jenis latihan dan proses ini dilakukan setelah Random Forest menghasilkan klasifikasi. Sistem memantau perubahan arah sudut untuk membentuk satu siklus yang berlangsung dari penutupan siklus sebelumnya sampai penutupan berikutnya. Ketika arah sedang turun maka kenaikan sudut minimal 8° dari nilai terendah digunakan untuk mengubah arah menjadi naik. Siklus baru ditutup ketika arah sedang naik lalu sudut menurun minimal 8° dari nilai tertinggi dan jarak dari perubahan arah sebelumnya minimal 0,5 detik.

Alur modul evaluasi siklus gerakan dapat dilihat pada Gambar 3.5.



Gambar 3.5 Flowchart Modul Evaluasi Siklus Gerakan

Setelah satu siklus ditutup, berikutnya sistem akan memeriksa data *window* yang terkumpul. Hanya *window* yang memiliki hasil klasifikasi dan nilai sudut yang dapat digunakan pada proses evaluasi. Rentang sudut dihitung dari selisih antara nilai sudut tertinggi dan nilai sudut terendah pada satu siklus. Data dipastikan memiliki jumlah minimal tiga *window* dan memiliki rentang sudut minimal 12° untuk squat, 12° untuk bench press, serta 14° untuk deadlift. Apabila syarat tersebut tidak terpenuhi maka hasil evaluasi siklus dibuat kosong. Jika data tersebut telah memenuhi syarat, sistem menentukan batas 30% bagian tertinggi dari rentang sudut yang telah dihitung. *Window* dengan nilai sudut yang berada pada bagian tersebut tidak digunakan pada proses penentuan kelas. Setelah itu, jumlah *window* yang tersisa diperiksa kembali dan harus berjumlah minimal tiga.


Hasil evaluasi kemudian ditentukan menggunakan *majority vote* dengan memilih kelas yang paling sering muncul dari *window* yang tersisa. Setelah hasil evaluasi diperoleh, data *window* pada siklus tersebut dikosongkan untuk menerima data siklus berikutnya. Sistem kemudian membentuk hasil evaluasi yang berisi kelas siklus dan teks peringatan apabila diperlukan lalu mengirimkannya ke sisi *client*. Hasil siklus tetap dikirim meskipun kelas yang diperoleh kosong. Jumlah siklus yang dianalisis dapat berbeda dengan jumlah repetisi karena kedua modul berjalan secara terpisah dan menggunakan parameter yang berbeda.

Proses	Parameter	Nilai
Perubahan Arah	Perubahan sudut minimum	8°
Perubahan Arah	Jarak minimum perubahan arah	0,5 detik
Pemeriksaan Siklus	Minimum <i>window</i>	3 <i>window</i>
Pemeriksaan Siklus	Rentang sudut minimum squat	12°
Pemeriksaan Siklus	Rentang sudut minimum bench press	12°
Pemeriksaan Siklus	Rentang sudut minimum deadlift	14°
Penyaringan <i>Window</i>	Bagian rentang sudut tertinggi	30%
Penentuan Kelas	Metode	<i>Majority vote</i>

Tabel 3.7 Parameter Modul Evaluasi Siklus Gerakan

3.3.3.5 Modul Antarmuka Aplikasi

Modul antarmuka aplikasi digunakan sebagai bagian yang berinteraksi langsung dengan pengguna selama proses latihan. Pada halaman awal, pengguna dapat memilih jenis latihan yaitu *bench press*, *squat*, atau *deadlift*, kemudian memilih sumber video dari kamera maupun video yang diunggah. Setelah pilihan ditentukan, pengguna dapat memulai proses analisis sesuai dengan jenis latihan yang dipilih. Tampilan awal tersebut digunakan agar pengguna dapat menentukan latihan dan sumber video sebelum proses analisis dimulai.




Gambar 3.6 Tampilan Pemilihan Latihan dan Input Video

Gambar 3.6 menunjukkan tampilan awal aplikasi yang digunakan untuk memilih jenis latihan dan sumber video sebelum proses latihan dimulai.

Setelah proses latihan dimulai, aplikasi menampilkan video pengguna yang dilengkapi dengan *bounding box* dan *skeleton pose*. Selain itu, antarmuka menampilkan informasi jumlah repetisi dan hasil evaluasi postur selama latihan berlangsung. Apabila terdapat kesalahan postur pada satu siklus gerakan, aplikasi memberikan peringatan dalam bentuk teks dan suara. Hasil pengolahan dari sisi *server* dikirim kembali ke sisi *client* untuk ditampilkan kepada pengguna, sedangkan sisi *client* juga menangani input video, deteksi manusia, ekstraksi *landmark*, dan visualisasi hasil. Pembagian proses

tersebut mengikuti arsitektur *client-server* yang telah dijelaskan pada Subbab 3.3.2.



Gambar 3.7 Tampilan Proses Latihan

Gambar 3.7 menunjukkan tampilan ketika proses latihan berlangsung yang berisi visualisasi *bounding box*, *skeleton pose*, jumlah repetisi, serta hasil evaluasi postur.

Setelah sesi latihan selesai, pengguna dapat melihat ringkasan hasil latihan. Ringkasan tersebut menampilkan jumlah repetisi dan hasil evaluasi kesalahan postur yang terjadi selama latihan. Gambar kondisi gerakan pada siklus yang terdeteksi salah juga ditampilkan agar pengguna dapat melihat kembali kondisi gerakan yang dilakukan. Hasil ringkasan hanya digunakan selama sesi aplikasi dan tidak disimpan sebagai riwayat latihan secara permanen karena aplikasi tidak menggunakan database maupun akun pengguna.



Gambar 3.8 Tampilan Ringkasan Latihan

Gambar 3.8 menunjukkan ringkasan hasil latihan yang berisi jumlah repetisi serta hasil evaluasi kesalahan postur yang terjadi selama sesi latihan.

Daftar Pustaka

Ko, Yeong-Min, Aziz Nasridinov, and So-Hyun Park. Real-Time AI Posture Correction for Powerlifting Exercises Using YOLOv5 and MediaPipe. *IEEE Access*, 2024. <https://doi.org/10.1109/ACCESS.2024.3516723>

Raza, Ali, Muhammad Haroon Yousaf, Waqar Ahmad, Sergio A. Velastin, and Serestina Viriri. Human Fall Detection Using Pose Estimation: From Traditional Machine Learning to Vision Transformers. *Engineering Applications of Artificial Intelligence*, 2025. <https://doi.org/10.1016/j.engappai.2024.109809>

Hsu, Y. C., Efstratios, T., & Tsui, K.-L. (2024). Viewpoint-invariant exercise repetition counting. *Health Information Science and Systems*, 12, 1. <https://doi.org/10.1007/s13755-023-00258-3>

Qi, Teng, Miyuki Iwamoto, Dongeun Choi, Noriyuki Kida, and Noriaki Kuwahara. Frailty-Focused Movement Monitoring: A Single-Camera System Using Joint Angles for Assessing Chair-Based Exercise Quality. *Sensors*, 2025. <https://doi.org/10.3390/s25133907>

Farhani, Ghazal, Yue Zhou, Patrick Danielson, and Ana Luisa Trejos. Implementing Machine Learning Algorithms to Classify Postures and Forecast Motions When Using a Dynamic Chair. *Sensors*, 2022. <https://doi.org/10.3390/s22010400>

Kongchansawang, P., Naowavathong, T., Srisuttee, R., & Moodleah, S. (2025). Automated classification of user exercise poses in virtual reality using machine learning-based human pose estimation. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2025.3622115>

Hamilton, R. I., Glavcheva-Laleva, Z., Milon, M. I. H., Anil, Y., Williams, J., Bishop, P., & Holt, C. (2024). Comparison of computational pose estimation models for joint angles with 3D motion capture. *Journal of Bodywork and Movement Therapies*, 40, 315–319.

<https://doi.org/10.1016/j.jbmt.2024.04.033>

Jocher, G., & Qiu, J. (2024). *Ultralytics YOLO11*. Ultralytics.

<https://docs.ultralytics.com/models/yolo11/>

Arrowsmith, C., Burns, D., Mak, T., Hardisty, M., & Whyne, C. (2023). Physiotherapy exercise classification with single-camera pose detection and machine learning. *Sensors*, 23(1), 363.

<https://doi.org/10.3390/s23010363>

Lee, D.-J., Noh, Y.-B., Byun, J., & Hwang, K.-I. (2026). Reinforcement learning-based golf swing correction framework incorporating temporal rhythm and kinematic stability. *Sensors*, 26(2), 392. <https://doi.org/10.3390/s26020392>

Zhu, F., & Zhu, R. (2021). Dance action recognition and pose estimation based on deep convolutional neural network. *Traitement du Signal*, 38(2), 529–538.

<https://doi.org/10.18280/ts.380233>